
PROYECTO CAPACITACIÓN

Predicción Mundial 2026

Memoria técnica y retrospectiva del modelo

*La historia completa —decisiones, matemáticas y lecciones— del sistema
que predijo a la campeona del mundo antes del torneo*

Documento de referencia: *Predicción Mundial 2026 — Reporte del modelo*, 10 de junio de 2026
Motor: `mundial_toto.ipynb` (notebook autocontenido, 26 celdas)
Resultado principal: Campeona (España) y final (España–Argentina) exactas
Período cubierto: 10 de junio – 19 de julio de 2026
Elaborado por: Alfonso Moraga

Julio de 2026

Resumen. El 10 de junio de 2026, antes del partido inaugural, este proyecto publicó un pronóstico fechado: la final más probable del Mundial era España–Argentina, con España campeona. El 19 de julio, España venció 1–0 a Argentina en la prórroga. Este documento cuenta, para un lector que llega sin ningún contexto, cómo se construyó ese pronóstico y por qué se tomó cada decisión. Está organizado en cinco partes que siguen la vida del proyecto —el contexto, la construcción, la prueba, el torneo y el legado— y usa un mismo partido real (el inaugural, México–Sudáfrica) como hilo conductor a través de todo el sistema. La narrativa lleva la delantera; las fórmulas acompañan como complemento, siempre después de la intuición que las explica.

El proyecto en una página

Qué es. Un sistema de predicción probabilística del Mundial 2026 construido con dos archivos públicos (49,272 partidos históricos y el valor de las 48 plantillas), seis modelos combinados y 30,000 simulaciones del torneo — operado en vivo con seis reentrenamientos durante la copa.

Qué logró. El 10 de junio, antes del primer partido, publicó con fecha su pronóstico. El 19 de julio, la realidad lo confirmó:

Lo que importa	Resultado
Campeona y final exactas, publicadas antes del torneo	España; España–Argentina ✓
Clasificados de la fase de grupos acertados	27 de 32 (84%)
Resultados 1X2 correctos en los 72 partidos	45 (62.5%; se prometió $\approx 56\%$)
Calidad de las probabilidades (log-loss; menor es mejor)	0.861 real vs. 0.943 prometido
Ganadores pronosticados de cuartos a la final	7 de 7

Cómo lo logró. Tres reglas valen más que cualquier fórmula: (1) la información fluye solo del pasado al futuro — ninguna señal conoce su propio partido; (2) toda mejora se demuestra contra un examen de 10 torneos pasados antes de entrar al sistema; (3) todo número publicado nace del modelo, nunca de un teclado.

Qué sigue. El sistema es reproducible en ~ 2 minutos en una computadora normal, y deja un backlog priorizado para el Mundial 2030 (datos de eventos xG, modelo de penales, automatización). Este documento explica cada pieza y cada decisión: las secciones 1–3 dan el contexto sin tecnicismos; la matemática, siempre opcional, acompaña en bloques marcados.

Índice

El proyecto en una página	1
PARTE I — El contexto	3
1 La historia en una página	3
2 El escenario: el Mundial 2026 y el reto del proyecto	3
3 Qué significa “predecir”: probabilidades y cómo se califican	4
PARTE II — La construcción del modelo	6
4 Los datos: con qué contábamos (y qué decidimos no usar)	6
5 Medir la fuerza: el rating Elo	7
6 La fotografía del partido: once señales y una regla sagrada	8
7 Seis maneras de opinar: el panel de modelos	9
8 De seis opiniones a una: la mezcla y la honestidad	11
PARTE III — La prueba de fuego	13
9 El examen: diez torneos y una regla de oro	13
10 Del partido al torneo: 30,000 Mundiales	14
PARTE IV — El torneo	16
11 La apuesta del 10 de junio	16
12 El torneo en vivo: seis reentrenamientos y una lección	17
13 El veredicto: cuánto fue señal y cuánto moneda	19
PARTE V — El legado	22
14 Rumbo a 2030: mejoras y reproducción	22
15 Preguntas frecuentes	22
16 Conclusión	23
A La comparación completa: el 10 de junio contra el torneo real, fase por fase	24
B Hoja de parámetros (v2, para copiar en 2030)	29
C Registro consolidado de decisiones	29
D Mapa de archivos del proyecto	30
E Glosario	31

PARTE I

El contexto

Esta parte te da todo lo necesario para leer el resto sin haber visto nunca el proyecto: qué es este documento (sección 1), en qué consistía el torneo y el reto (sección 2), y qué significa exactamente “predecir” cuando se habla en probabilidades (sección 3). Al terminarla sabrás qué se prometió entregar y con qué vara se mide si se cumplió.

1 La historia en una página

¿Qué es este documento y qué historia cuenta? Un mapa de dos minutos antes de empezar.

Todo empezó como un ejercicio de capacitación: estimar las probabilidades de los 72 partidos de la fase de grupos del Mundial 2026, usando solamente el historial de partidos internacionales. El ejercicio creció. Primero, hacia la pregunta que todos hacen de verdad —¿quién va a ser campeón?—, lo que obligó a simular el torneo completo con sus reglas. Después, hacia el rigor: ¿cómo sabemos que el modelo sirve, *antes* de que empiece el torneo? Y al final, hacia la operación: cuando el Mundial arrancó, el sistema se reentrenó seis veces con los resultados reales, ajustando sus pronósticos ronda a ronda.

El 10 de junio se publicó el reporte pre-torneo con una apuesta en la portada: España campeona (14.6%), final España–Argentina. Era una apuesta arriesgada de contar: 14.6% significa que *no* ocurre 6 de cada 7 veces. Ocurrió. Y más importante que el titular: las mediciones serias del modelo —qué tan buenas eran sus probabilidades partido a partido— salieron *mejores* en el Mundial real que en su propio examen de práctica.

Este documento está escrito para que lo entienda alguien que llega sin contexto. Por eso: (a) está organizado en **cinco partes** que siguen la vida del proyecto, cada una abierta con una guía de qué contiene; (b) cada sección arranca con una línea en cursiva que dice *qué pregunta responde*; (c) un mismo partido real —el inaugural, **México vs. Sudáfrica**— recorre todo el sistema como **hilo conductor**, en recuadros ámbar: verás sus números pasar por el rating, las señales, los modelos, la mezcla y la simulación, hasta su resultado real; y (d) las fórmulas viven en párrafos marcados “En símbolos”, siempre *después* de la explicación: puedes saltarlas todas sin perder la trama.

2 El escenario: el Mundial 2026 y el reto del proyecto

¿Cómo funcionaba el torneo que había que predecir, y qué se comprometió a entregar el proyecto?

El Mundial 2026 (Estados Unidos, México y Canadá; 11 de junio – 19 de julio) fue el más grande de la historia: **48 selecciones** repartidas en **12 grupos de 4**. En cada grupo, todos juegan contra todos (6 partidos por grupo, 72 en total). Avanzan a la fase eliminatoria los dos primeros de cada grupo *más los 8 mejores terceros* — 32 clasificados. Desde ahí, eliminación directa: dieciseisavos, octavos, cuartos, semifinales y la final en Nueva Jersey. Dos detalles del formato importan mucho para este documento: los *mejores terceros* se acomodan en lugares específicos del cuadro según una tabla del reglamento (no al azar), y en la eliminación directa un empate se resuelve con prórroga

y penales.

El proyecto se comprometió a entregar, *antes del torneo*: las probabilidades de los tres resultados posibles de cada uno de los 72 partidos de grupos; los clasificados más probables; la probabilidad de cada selección de alcanzar cada ronda, hasta la de ser campeona; y el cuadro eliminatorio más probable, con marcadores. Y durante el torneo: mantener todo eso actualizado con los resultados reales.

Dos palabras que usaremos constantemente, definidas de una vez. Un **modelo** es un procedimiento que convierte datos de entrada (aquí: la historia de dos selecciones) en una salida (aquí: probabilidades del partido). **Entrenar** un modelo es ajustar sus perillas internas usando ejemplos del pasado con respuesta conocida, para que aprenda la relación entre entradas y salidas. Todo el sistema vive en un *notebook* —un documento de código ejecutable— que corre de principio a fin en unos dos minutos.

El hilo conductor — México vs. Sudáfrica. Lo presentamos de una vez, porque nos acompañará todo el documento. **11 de junio de 2026, Estadio Azteca, partido inaugural: México vs. Sudáfrica.** El 10 de junio, el sistema publicó para este partido: **México 71%, empate 19%, Sudáfrica 10%**, marcador más probable 1-0. En las siguientes secciones veremos exactamente de dónde salieron esos tres números. (Si quieres saber cómo terminó: paciencia hasta la Parte IV... o salta al final del hilo en sección 11.)

3 Qué significa “predecir”: probabilidades y cómo se califican

Ya sabemos qué había que predecir. Ahora: ¿en qué moneda habla un pronóstico, y con qué vara se mide?

La primera decisión del proyecto fue de filosofía, no de código: el sistema **nunca dice quién va a ganar; dice con qué probabilidad**. Un partido tiene tres resultados posibles —gana el local, empate, gana el visitante (el clásico “1X2”)— y el entregable por partido son tres números que suman 100%, como los del hilo conductor: 71/19/10. Todo lo demás que produce el sistema (clasificados, cuadro, campeón) se construye apilando esas ternas.

Esto cambia cómo se juzga al sistema, y es crucial entenderlo antes de seguir. Si el modelo dice “México 71%” y México pierde, el modelo *no* se equivocó necesariamente: dijo que eso pasaría 3 de cada 10 veces. Entonces, ¿cómo se califica a alguien que habla en probabilidades? Con dos preguntas:

Primera: ¿pusiste probabilidad alta a lo que sí ocurrió? La métrica que lo mide se llama *log-loss*: premia haberle dado mucha probabilidad al resultado real y castiga con dureza la confianza equivocada — decir 90% y fallar duele muchísimo más que decir 55% y fallar. Es la métrica principal del proyecto: **toda decisión de diseño se tomó mirándola**.

Segunda: ¿tus porcentajes son honestos? Si juntamos todos los momentos en que el sistema dijo “70%”, ¿ocurrieron esas cosas el 70% de las veces? Eso es la *calibración*. Un pronosticador puede ser útil sin ser adivino, siempre que sus números signifiquen lo que dicen.

Guarda estas dos varas: reaparecen en el examen (sección 9), en la apuesta publicada (sección 11) y en el veredicto final (sección 13).

FORMULACIÓN MATEMÁTICA

Un pronóstico para el partido m es la terna

$$p_m = (p_m^H, p_m^D, p_m^A), \quad p_m^k \geq 0, \quad p_m^H + p_m^D + p_m^A = 1, \quad (1)$$

donde:

- p_m^H — probabilidad de que gane el equipo local
- p_m^D — probabilidad de empate
- p_m^A — probabilidad de que gane el visitante

La **log-loss** (primera vara) sobre un conjunto de N partidos es

$$\mathcal{L} = -\frac{1}{N} \sum_{m=1}^N \log p_m(y_m), \quad (2)$$

donde:

- y_m — el resultado que realmente ocurrió en el partido m (local, empate o visita)
- $p_m(y_m)$ — la probabilidad que el modelo le había asignado a ese resultado
- N — el número de partidos evaluados

El **error esperado de calibración** (segunda vara) es

$$\text{ECE} = \sum_{b=1}^B \frac{n_b}{n} \left| \overline{\text{conf}}_b - \overline{\text{frec}}_b \right|, \quad (3)$$

donde:

- B — número de grupos (*bins*) en que se agrupan las probabilidades emitidas
- n_b — cuántas probabilidades cayeron en el grupo b (y n el total)
- $\overline{\text{conf}}_b$ — la probabilidad promedio *prometida* en el grupo b (p. ej. “70%”)
- $\overline{\text{frec}}_b$ — la frecuencia con que esas cosas *ocurrieron* de verdad

Referencias de escala: el pronóstico uniforme $(\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ da $\mathcal{L} = \ln 3 \approx 1.099$; los buenos modelos de selecciones rondan 0.93–1.00. También se reportan RPS y Brier, variantes cuadráticas (glosario).

PARTE II

La construcción del modelo

Con el reto y la vara claros, construimos. Esta parte sigue el orden natural de la tubería: primero los ingredientes (sección 4), luego la vara de fuerza de cada selección (sección 5), la fotografía de cada partido (sección 6), los seis modelos que opinan sobre ella (sección 7) y la manera de fundir seis opiniones en una sola, honesta (sección 8). El hilo conductor cruza cada estación: al final de la parte, los 71/19/10 del partido inaugural habrán quedado completamente explicados.

La Figura 1 muestra el sistema completo de un vistazo; las secciones de esta parte recorren sus cajas de izquierda a derecha.




Figura 1: El sistema de un vistazo. El flujo principal va de izquierda a derecha (secciones 4 a 10); el examen (sección 9) valida cada componente antes de confiar en él, y el modo en vivo (sección 12) realimenta los resultados reales durante el torneo.

4 Los datos: con qué contábamos (y qué decidimos no usar)

¿De dónde sale todo? Dos archivos públicos — y tres tentaciones rechazadas por escrito.

El proyecto se apoyó en una sola gran fuente: `results.csv`, el historial de **49,272 partidos internacionales desde 1872** hasta tres días antes del torneo — fecha, selecciones, goles, torneo, sede y si la cancha fue neutral. Un detalle de diseño que simplificó todo: los 72 partidos del fixture 2026 viven en el mismo archivo, como filas con marcador vacío. Así “pasado” y “futuro” son el mismo dataset, y una sola bandera los separa: lo que tiene marcador entrena; lo que no, se predice.

La única fuente externa fue `squad_2026.csv`: el valor de mercado de cada plantilla según Transfermarkt. ¿Por qué agregarla? Porque el historial tiene memoria lenta: una generación dorada joven (goles aún no dados) vale más de lo que dicen sus resultados pasados, y el valor de mercado es un atajo hacia esa información. Como los valores van de ~£20M (Curazao) a ~£1,200M (Inglaterra), se usa el logaritmo estandarizado: importa el orden de magnitud, no las libras.

Decisión 4.1 (Lo que se dejó fuera, a propósito). Tres fuentes tentadoras se excluyeron con razones escritas. Las *cuotas de apuestas* habrían mejorado la log-loss, pero convierten al modelo en un espejo del mercado: se pierde el mérito (y el aprendizaje) de predecir por cuenta propia. El *ranking FIFA* es redundante con nuestro propio rating y metodológicamente inferior. Los *datos de eventos*

(xG) eran la mejora soñada, pero su cobertura pública en 2026 (unos 280 partidos de 5 torneos) no alcanzaba para entrenar sin sesgos; quedó formalmente pospuesta para 2030 (sección 14).

El hilo conductor — México vs. Sudáfrica. En `results.csv`, México aparece en 1,002 partidos históricos y Sudáfrica en 478. El partido inaugural es una fila con marcador vacío: fecha 2026-06-11, ciudad México, cancha *no* neutral — dato que importará mucho en la siguiente sección.

5 Medir la fuerza: el rating Elo

¿Cómo se compara a dos selecciones que casi nunca juegan entre sí? Con una vara común que destila toda su historia en un número.

México y Sudáfrica habían jugado entre sí un puñado de veces en 150 años. Para compararlos hace falta una vara común, y la respuesta clásica es el *rating Elo*, nacido en el ajedrez: cada selección lleva una calificación que sube al ganar y baja al perder, y —esta es la clave— **lo que importa es a quién le ganas**. Vencer al líder mundial suma mucho; vencer al colista, casi nada. El sistema procesa los 49,272 partidos en orden cronológico, actualizando calificaciones partido a partido; al llegar al Mundial, cada selección trae su historia entera destilada en un número. España llegó con el más alto (2291); México, con 1999; Sudáfrica, con 1662.

Sobre la base clásica se montaron tres ajustes futboleros: un partido de Mundial mueve el rating el doble que un amistoso (la seriedad importa); una goleada mueve más que un 1–0, pero con freno logarítmico (ganar 7–0 no es siete veces ganar 1–0); y jugar en casa —en tu país, cancha no neutral— vale una bonificación de 100 puntos en la comparación previa.

Decisión 5.1 (La localía: de 55 a 100 puntos, con evidencia). La versión original usaba +55 puntos de localía. Al investigar el estado del arte encontramos que el estándar de referencia (elratings.net [2]) usa +100. No se cambió por autoridad: se probaron 55, 80, 100 y 120 contra el examen de la sección 9. Ganó 100 (log-loss 0.9454 $\rightarrow$ 0.9432; con 80: 0.9439; con 120: 0.9443). Fue la mejora individual más grande del proyecto y el mejor ejemplo del método: la literatura propone, el examen decide.

El hilo conductor — México vs. Sudáfrica. México 1999 + 100 de localía real contra Sudáfrica 1662: diferencia efectiva de 437 puntos. En la escala Elo, esa diferencia se traduce en una *expectativa* de 92% para México. ¿Entonces por qué el pronóstico publicado fue 71% y no 92%? Porque la expectativa Elo cuenta el empate como “medio triunfo” y no distingue entre ganar y empatar — separar esas cosas es trabajo de los modelos de la sección 7. El 92% es materia prima, no pronóstico.

FORMULACIÓN MATEMÁTICA

Antes del partido, la **diferencia efectiva** y la **expectativa** del local son

$$d = R_H + 100 \cdot \mathcal{K}[\text{localía real}] - R_A, \quad E = \frac{1}{1 + 10^{-d/400}}, \quad (4)$$

donde:

- R_H, R_A — los ratings Elo del local y del visitante antes del partido
- $\mathbb{I}[\cdot]$ — vale 1 si el partido se juega en el país del local en cancha no neutral; 0 si no
- 100 — la bonificación de localía (Decisión 5.1)
- d — la ventaja neta del local, en puntos Elo
- E — la expectativa del local: entre 0 y 1, cuenta el empate como medio triunfo

Tras conocer el resultado, ambos ratings se mueven en direcciones opuestas una magnitud

$$\Delta = K \cdot W_{\text{torneo}} \cdot (1 + \ln(1 + |\Delta g|)) \cdot (S - E), \quad (5)$$

donde:

- $K = 24$ — la sensibilidad base del rating (cuánto puede moverse por partido)
- W_{torneo} — la seriedad del partido: Mundial 2.0, continentales 1.6, eliminatorias 1.4, Nations League 1.2, amistosos 0.75
- $|\Delta g|$ — el margen de goles; el logaritmo frena las goleadas extremas
- S — el resultado del local: 1 victoria, $\frac{1}{2}$ empate, 0 derrota
- $S - E$ — la *sorpres*a: cuánto mejor (o peor) saliste de lo esperado

Para el hilo conductor: $d = 1999 + 100 - 1662 = 437$, y por tanto $E = 1/(1 + 10^{-437/400}) \approx 0.92$.

6 La fotografía del partido: once señales y una regla sagrada

El Elo resume la historia larga; un partido se juega en el presente. ¿Qué más hay que mirar — y qué está prohibido mirar?

Cada cruce se describe con once señales que comparan a los dos equipos. Las dos primeras salen del Elo: la diferencia (¿quién es más fuerte?) y su *magnitud* (¿qué tan parejos son? — dos equipos parejos empatan más, y el modelo necesita ver esa cercanía como señal propia). La tercera es la localía real. Las siguientes miran el presente: la racha de los últimos diez partidos (puntos por partido), los goles a favor y en contra recientes, y la *dificultad de los rivales* enfrentados en esa racha — porque 10 puntos contra potencias no valen lo mismo que contra débiles. Las últimas miran el contexto: experiencia mundialista acumulada (con saturación: el partido 40 enseña menos que el 5), si comparten confederación, y qué tan activo estuvo cada equipo en los últimos dos años. Esta última señal alimenta además una **etiqueta de honestidad**: si una selección jugó menos de 18 partidos en 24 meses, sus pronósticos se marcan de *baja confianza* (les pasó a los partidos de Irán).

Y aquí vive la **regla sagrada del proyecto**: para describir un partido solo se usa información *anterior* a ese partido. Suena obvio; es el error más común del pronóstico deportivo (se llama *leakage*: dejar que el futuro se filtre al pasado durante el entrenamiento, inflando la precisión de mentira). Nuestra garantía no es una auditoría, es la construcción: el código recorre los partidos en orden cronológico y *primero* anota las señales, *después* procesa el resultado. Es físicamente imposible que una señal conozca su propio partido.

El hilo conductor — México vs. Sudáfrica. La fotografía del inaugural, en sus señales principales: diferencia de Elo +437 (grande), magnitud 437 (no es un partido parejo $\Rightarrow$ menos empate), localía real (sí: Azteca), racha reciente favorable a México, experiencia mundialista muy superior (60 partidos de Mundial contra 9), misma confederación (no: CONCACAF vs. CAF), y ambos con actividad sana en 24 meses (23 y 25 partidos: sin etiqueta de baja confianza).

FORMULACIÓN MATEMÁTICA

Sea $\mathcal{F}_t$ el conjunto de todos los partidos con fecha anterior a t . La regla sagrada, en una línea: toda señal x_m del partido m debe poder calcularse usando únicamente $\mathcal{F}_{t_m}$ — la propiedad *point-in-time*. Las once señales, todas como diferencia local menos visitante:

Señal	Definición	Qué mide
d_elo	$d/400$ (ec. 4)	La ventaja de fuerza, en la escala natural del modelo
abs_d_elo	$ d /400$	Qué tan parejos son (los parejos empatan más)
true_home	$\mathbb{I}[\text{localía real}]$	Si el local juega de verdad en casa
d_form	$\overline{\text{pts}}_{10,H} - \overline{\text{pts}}_{10,A}$	Racha: puntos por partido en los últimos 10
d_gf	$\overline{GF}_{10,H} - \overline{GF}_{10,A}$	Goles a favor recientes
d_ga	$\overline{GC}_{10,H} - \overline{GC}_{10,A}$	Goles en contra recientes
d_gd	$\overline{DG}_{10,H} - \overline{DG}_{10,A}$	Diferencia de gol reciente
d_sos	$(\overline{\text{Elo rivales}}_H - \overline{\text{Elo rivales}}_A)/400$	Dificultad del calendario reciente
d_wcexp	$\ln(1+n_H^{WC}) - \ln(1+n_A^{WC})$	Experiencia mundialista (n^{WC} : partidos de Mundial jugados), con saturación
same_confed	$\mathbb{I}[\text{misma confederación}]$	Familiaridad de estilos
d_recent	$n_H^{730} - n_A^{730}$	Actividad: partidos en los últimos 730 días

Tabla 1: Las once señales del modelo. Los subíndices “10” promedian los últimos 10 partidos de cada selección; todos los estadísticos se calculan sobre $\mathcal{F}_{t_m}$.

7 Seis maneras de opinar: el panel de modelos

Con la fotografía lista, ¿quién la interpreta? No un modelo: seis, elegidos para equivocarse de maneras distintas.

¿Por qué seis y no “el mejor”? Porque en pronóstico la diversidad paga: modelos distintos fallan en momentos distintos, y un buen promedio de opiniones imperfectas es más estable que cualquier opinión sola. El panel se armó buscando *maneras diferentes de mirar el mismo partido*:

Los dos clásicos. Una regresión logística que solo mira el Elo —la línea base: si algo más complejo no le gana, sobra— y una con las once señales completas, que terminó siendo, calladamente, el mejor modelo individual del examen. Lineales, estables, interpretables.

Los dos de aprendizaje automático. XGBoost y Random Forest, dos familias de “bosques de decisiones” capaces de capturar interacciones que los lineales no ven (¿la experiencia mundialista pesa más cuando los equipos son parejos?). Se configuraron *a propósito* conservadores —árboles poco profundos, aprendizaje lento— porque con once señales tabulares, un modelo flexible de más no aprende: memoriza.

El que habla en goles: Dixon–Coles. El único panelista que no opina “1X2” sino *marcadores*: modela cuántos goles anota cada equipo (el ataque de uno contra la defensa del otro) con la corrección clásica de Dixon y Coles [1] para marcadores bajos — los 0–0 y 1–1 ocurren más de lo que dictan las cuentas ingenuas. De él salen el “marcador más probable”, los goles esperados, las probabilidades de goleada... y los dados con que la Parte III simulará el torneo. En la versión 2 aprendió a *olvidar*: los partidos viejos pesan la mitad cada 3 años, y su parámetro de empates se

estima de los datos.

El que mira la cartera. Un modelo que solo usa la diferencia de valor de plantilla. Casi trivial — y valioso justo por eso: aporta información que ningún otro panelista tiene (sección 4). Su peso en la mezcla final, 45% y solo para partidos del Mundial 2026, no se eligió al gusto: se probó una malla de pesos contra partidos recientes nunca vistos por el modelo, y la curva marcó su óptimo entre 0.45 y 0.60; se tomó el extremo conservador.

El hilo conductor — México vs. Sudáfrica. Sobre el inaugural, el panel no vota igual: los modelos de señales ven la diferencia enorme de Elo y empujan la probabilidad de México muy arriba; el Dixon–Coles, mirando goles esperados (≈ 1.7 contra 0.6), reparte más masa al empate y al 1–0; el de valor de plantilla *frena* a México —la plantilla sudafricana no vale tanto menos como sugiere su Elo—. Seis opiniones distintas: falta fundirlas en una.

En resumen, el panel completo y el voto que terminó recibiendo cada uno:

Panelista	Mira	Aporta	Peso final
Elo-logit	solo el rating	la línea base	0.00
Logit multinomial	las 11 señales	el mejor juicio individual	0.55
XGBoost	las 11 señales	interacciones no lineales	0.00
Random Forest	las 11 señales	diversidad de sesgo	0.14
Dixon–Coles	goles esperados	marcadores y los dados de la simulación	0.25
Valor de plantilla	el mercado	lo que el historial aún no sabe	0.45 (solo Mundial 2026)

Tabla 2: El panel de seis modelos. Los pesos de los cinco primeros los aprendió el optimizador (sección 8); nótese cómo podó a dos panelistas redundantes. El del valor se mezcla aparte, al final.

FORMULACIÓN MATEMÁTICA

(a) Los modelos logísticos. El logit multinomial asigna las tres probabilidades directamente desde las once señales:

$$\Pr(Y = k \mid x) = \frac{\exp(\beta_k^\top x)}{\sum_{j \in \{H, D, A\}} \exp(\beta_j^\top x)}, \quad k \in \{H, D, A\}, \quad (6)$$

donde:

- x — el vector de las once señales del partido (Tabla 1), estandarizadas
- β_k — los coeficientes aprendidos para el resultado k (regularización ℓ_2 , $C = 0.5$)
- Y — el resultado del partido (el Elo-logit usa la misma forma con solo 3 señales, $C = 1$)

(b) Los de árboles no tienen fórmula cerrada; sus configuraciones (deliberadamente conservadoras) son: XGBoost con 600 árboles de profundidad 4, tasa de aprendizaje 0.03, submuestreo 0.8 y regularización $\lambda = 2$; Random Forest con 200 árboles de profundidad 8 y hojas de al menos 10 ejemplos.

(c) Dixon–Coles. Los goles esperados de cada equipo combinan el ataque propio con la defensa rival:

$$\lambda^H = \exp(\mu + \alpha_H + \delta_A + \gamma \cdot \mathcal{K}[\text{localía real}]), \quad \lambda^A = \exp(\mu + \alpha_A + \delta_H), \quad (7)$$

donde:

- μ — el nivel general de goles del fútbol internacional
- α_e — la capacidad *ofensiva* de la selección e (aprendida de sus goles anotados)
- δ_e — la debilidad *defensiva* de e (aprendida de sus goles recibidos)
- γ — el empuje extra de jugar en casa
- λ^H, λ^A — los goles esperados de local y visitante en este partido

La probabilidad de un marcador exacto (i, j) es el producto de dos Poisson, corregido en los marcadores bajos:

$$\Pr(i, j) = \tau_\rho(i, j) \cdot \frac{e^{-\lambda^H} (\lambda^H)^i}{i!} \cdot \frac{e^{-\lambda^A} (\lambda^A)^j}{j!}, \quad (8)$$

donde:

- i, j — los goles del local y del visitante en el marcador considerado
- $e^{-\lambda} \lambda^i / i!$ — la probabilidad Poisson de anotar exactamente i goles cuando se esperan λ
- $\tau_\rho(i, j)$ — la corrección de Dixon–Coles: infla o desinfla solo las celdas $(0, 0), (0, 1), (1, 0), (1, 1)$, gobernada por el parámetro ρ
- ρ — elegido probando una malla de valores sobre el 15% final del entrenamiento

Las observaciones de entrenamiento pesan $2^{-\Delta t/3 \text{ años}}$ (Δt : antigüedad del partido; ventana de 12 años): el modelo *olvida* gradualmente.

(d) **El de valor de plantilla** es un logit sobre una sola señal:

$$v = z(\log V_H) - z(\log V_A), \quad (9)$$

donde:

- V_e — el valor de mercado de la plantilla de e (Transfermarkt, millones de libras)
- $z(\cdot)$ — estandarización: media 0 y desviación 1 sobre las 48 selecciones

Su peso en la mezcla final se calibró en malla: $\mathcal{L}(w_V=0) = 1.024 \rightarrow \mathcal{L}(0.30) = 1.013 \rightarrow \mathcal{L}(0.45) = \mathcal{L}(0.60) = 1.011$; se eligió $w_V = 0.45$, el extremo conservador del tramo plano.

8 De seis opiniones a una: la mezcla y la honestidad

¿Cómo se combinan seis votos — y cómo se garantiza que el porcentaje final sea honesto?

Con pesos, pero pesos *aprendidos*, no asignados. Se reserva el tramo más reciente del pasado (el 30% final del entrenamiento, siempre cronológico — reservar partidos al azar dejaría colarse al futuro, violando la regla sagrada de sección 6) y se buscan los pesos que mejor habrían pronosticado ese tramo. El resultado tuvo una elegancia inesperada: el optimizador *podó solo*, dando peso cero a dos panelistas cuya información ya estaba contenida en los demás. Nadie decidió “sacar” un modelo; los datos lo decidieron.

Después de mezclar viene el paso que más distingue a un pronosticador serio: la **calibración**. Un solo número —la “temperatura”— enfría pronósticos sobreconfiados o afila pronósticos tibios, hasta que los porcentajes emitidos signifiquen lo que dicen (la segunda vara de sección 3). En el examen, cuando el sistema decía “70%”, la realidad rondaba el 70%: error de calibración global 0.015.

Decisión 8.1 (La honestidad sobre el ensemble). Medido con lupa, el ensemble completo ($\mathcal{L} = 0.943$) *empató* con el mejor modelo individual solo (0.942). ¿Por qué mantener seis modelos? Por estabilidad: el ensemble fue más parejo *entre* torneos distintos. La decisión quedó documentada

con su verdadera razón — robustez, no precisión. Un proyecto que se miente en lo pequeño terminará mintiéndose en lo grande.

El hilo conductor — México vs. Sudáfrica. Y aquí nacen los números publicados del inaugural: la mezcla calibrada de los seis votos produce **México 71%, empate 19%, Sudáfrica 10%** — el 92% crudo del Elo, atemperado por el empate (19% no es poco), por la prudencia del modelo de goles y por el freno del valor de plantilla. Marcador más probable, cortesía del Dixon–Coles: 1–0. Estos tres números quedaron impresos y fechados el 10 de junio. La cita con la realidad, en la Parte IV.

FORMULACIÓN MATEMÁTICA

La mezcla calibrada de los cinco panelistas históricos es

$$p^{\text{ens}} = \text{softmax}\left(\frac{1}{T} \log \sum_{i=1}^5 w_i p^{(i)}\right), \quad w_i \geq 0, \quad \sum_{i=1}^5 w_i = 1, \quad (10)$$

donde:

- $p^{(i)}$ — la terna de probabilidades que propone el panelista i
- w_i — el peso (voto) del panelista i , aprendido de los datos
- T — la *temperatura* de calibración: $T > 1$ enfría pronósticos sobreconfiados, $T < 1$ afila los tibios

softmax — renormaliza para que la terna final sume 1

Los valores (w, T) se eligen minimizando la log-loss (2) (método de Nelder–Mead) sobre el 30% cronológicamente más reciente del entrenamiento. En la corrida final: $w \approx (0, 0.55, 0, 0.14, 0.25)$ para (Elo-logit, logit, XGBoost, RF, Dixon–Coles) y $T \approx 0.93$. Para los partidos del Mundial 2026 se añade el sexto panelista:

$$p^{2026} = 0.55 p^{\text{ens}} + 0.45 p^{\text{valor}}. \quad (11)$$

PARTE III

La prueba de fuego

Un modelo construido no es todavía un modelo confiable. Esta parte cuenta cómo se ganó la confianza antes del torneo: el examen contra diez torneos del pasado (sección 9) y el salto del partido individual al torneo completo mediante simulación (sección 10).

9 El examen: diez torneos y una regla de oro

¿Por qué habría que creerle a este modelo? Porque tomó un examen que no podía hacer trampa — y publicó su calificación antes del torneo.

El examen consiste en **viajar al pasado**: pararse la víspera del Mundial 2014 —fingiendo no saber nada de lo que vino después—, entrenar solo con lo anterior, predecir sus 64 partidos y calificarse contra la historia. Y así con diez torneos: Mundiales 2014, 2018, 2022; Eurocopas 2016, 2021, 2024; Copas América 2019, 2021, 2024; y la Copa Asiática 2019. En total, **482 partidos de examen genuino**, promediando por torneo para que el Mundial (64 partidos) no ahogue a la Copa América (26). El resultado, publicado como promesa verificable: log-loss 0.943 —14% más informativo que el azar—, 56% de acierto y calibración 0.015 (Tabla 3).

Decisión 9.1 (La regla de oro). *Ninguna mejora entra al sistema sin ganar este examen.* Cada idea, por razonable que sonara, se implementó como variante y se midió. Entraron: la localía de 100 (sección 5), el olvido gradual del Dixon–Coles y el peso por recencia en los modelos de aprendizaje —juntas, $0.9454 \rightarrow 0.9428$, mejor en 7 de 10 torneos, 89% de probabilidad de mejora real. No entraron: el olvido agresivo (semivida 4 años, empeoró) ni las localías de 80 y 120. Esta disciplina —no ninguna fórmula— es el corazón del proyecto y lo primero que debe recrearse en 2030.

Modelo	log-loss	RPS	Brier	ECE	Acierto
Logit multinomial	0.942	0.185	0.559	0.067	55.3%
XGBoost	0.942	0.185	0.559	0.077	55.8%
Ensemble (final)	0.943	0.185	0.559	0.074	56.4%
Elo-logit	0.947	0.186	0.562	0.074	55.9%
Random Forest	0.956	0.189	0.568	0.069	55.3%
Dixon–Coles	0.995	0.202	0.596	0.074	52.3%
Azar uniforme	1.099	0.222	0.667	—	33.3%

Tabla 3: El examen: backtest *rolling-origin* sobre 10 torneos (482 partidos).

La calificación no fue pareja entre torneos — y eso también es información honesta. La Tabla 4 muestra la log-loss del ensemble en cada uno de los diez exámenes: la Copa Asiática 2019 fue el más “fácil” (0.79, favoritos claros) y la Eurocopa 2016 el más difícil (1.09, el torneo de las sorpresas de Gales e Islandia). Esta variabilidad es la razón de promediar por torneo y de exigir que las mejoras ganen en la mayoría de las ediciones, no solo en el promedio.

Torneo	log-loss	Torneo	log-loss
Copa Asiática 2019	0.79	Eurocopa 2024	1.00
Copa América 2024	0.87	Mundial 2022	1.03
Copa América 2021	0.89	Eurocopa 2016	1.09
Mundial 2014	0.93		
Eurocopa 2021	0.93	<i>Promedio: 0.943</i>	
Copa América 2019	0.95	<i>Azar: 1.099</i>	
Mundial 2018	0.97		

Tabla 4: El examen, torneo por torneo (log-loss del ensemble; menor es mejor).

Sobre métricas descartadas: F1 y AUC miran solo “a quién elegiste”, tirando las probabilidades que son el producto entero; MAPE y familia son de regresión y no aplican. La selección sigue la literatura [3].

10 Del partido al torneo: 30,000 Mundiales

Saber el 71% de un partido no responde “¿quién será campeón?”. Entre medio hay reglas, terceros y cruces. La solución honesta: jugar el torneo. Muchas veces.

En cada una de las 30,000 réplicas, la computadora sortea cada partido según sus probabilidades — con una sutileza de diseño: primero sortea el *resultado* (con las ternas del ensemble, que es el mejor juez del 1X2) y después un *marcador* del Dixon–Coles compatible con ese resultado. Cada componente hace lo que mejor sabe. Luego arma las tablas con las reglas FIFA, acomoda a los ocho mejores terceros en sus lugares del cuadro (un problema de asignación resuelto con el algoritmo húngaro sobre las combinaciones que permite el reglamento [7]), y recorre la eliminación directa hasta coronar campeón — con los cruces empatados resueltos como moneda cargada al favorito (la aproximación de penales). Contar réplicas es contar probabilidades: si España es campeona en 4,380 de 30,000, su probabilidad es 14.6%. **Todos los porcentajes del reporte se leen así.**

Cada cambio al sistema disparaba **revisiones de sentido común** automatizadas: deben clasificar exactamente 32, las probabilidades de campeón deben sumar 100%, cada terna debe sumar 1. Baratas, y capaces de atrapar casi cualquier error de plomería antes de llegar a un reporte.

El hilo conductor — México vs. Sudáfrica. En las 30,000 réplicas, México ganó el inaugural en ~21,300 (71%, consistente por construcción), quedó 1º del grupo A en el 60% y avanzó a dieciseisavos en el 84%. Su probabilidad de título: 2.0% — lejos del top-10. El sistema veía a México fuerte en casa, pero un escalón bajo las cinco potencias. (Spoiler de la Parte IV: llegó exactamente hasta donde su probabilidad decía que era su techo típico.)

FORMULACIÓN MATEMÁTICA

En cada réplica, el resultado y el marcador de cada partido se sortean en dos pasos encadenados:

$$Y \sim p^{2026}, \quad (g^H, g^A) \sim \Pr(\cdot \mid (g^H, g^A) \in \mathcal{R}(Y)), \quad (12)$$

donde:

- Y — el resultado 1X2 sorteado con las probabilidades del ensemble
 $\mathcal{R}(Y)$ — el conjunto de marcadores compatibles con ese resultado (p. ej. si $Y = \text{empate}$: 0-0, 1-1, 2-2, ...)
- (g^H, g^A) — el marcador, sorteado de la matriz Dixon-Coles (8) restringida a $\mathcal{R}(Y)$

En la eliminación directa, la probabilidad de avanzar de cada cruce es

$$\text{ADV}_{ij} = p_{ij}^W + \frac{1}{2} p_{ij}^D, \quad (13)$$

donde:

- p_{ij}^W — probabilidad de que i le gane a j en 90 minutos (cancha neutral)
 p_{ij}^D — probabilidad de empate entre ambos
 $\frac{1}{2} p_{ij}^D$ — la aproximación de prórroga y penales: el empate se reparte por igual

Invariantes verificados tras cada cambio: $\sum_e \pi_R(e)$ debe valer exactamente 32, 16, 8, 4, 2, 1 según la ronda R , y cada terna 1X2 debe sumar 1.

PARTE IV

El torneo

Llega la realidad. Esta parte confronta la apuesta publicada con lo que pasó: el recorrido del reporte del 10 de junio con sus veredictos (sección 11), la operación en vivo con sus seis reentrenamientos y su gran lección (sección 12), y el veredicto completo — incluyendo la pregunta incómoda de cuánto fue mérito y cuánto suerte (sección 13).

11 La apuesta del 10 de junio

El documento contra el que se califica todo lo demás: qué decía exactamente — y qué pasó con cada cosa que dijo.

El reporte pre-torneo (14 páginas, `10dejunio.pdf`) es el documento contra el que se califica todo lo demás. Su portada declaraba, con fecha: «*Favorito al título: España · 14.6% ... Final más probable del cuadro: España vs Argentina*». Un pronóstico fechado no se puede maquillar después; esa transparencia es lo que hace valioso el acierto. Lo recorremos por secciones, cada una con su veredicto.

La portada: la apuesta pública

Campeona y final declaradas antes del primer silbatazo. **Veredicto: España campeona, final España–Argentina. Pleno.**

El resumen ejecutivo: los favoritos

Publicaba el top-10 —España 14.6%, Francia 9.3%, Argentina 9.2%, Brasil 8.3%, Inglaterra 8.1%...— recordando que había 85% de que el campeón fuera otro. **Veredicto: los cuatro semifinalistas reales ocuparon los puestos 1, 2, 3 y 5 del ranking; solo Brasil (4º) cayó antes, eliminado por Noruega.**

La validación: la promesa de rendimiento

Prometía números concretos y verificables: $\log\text{-loss} \approx 0.94$ y acierto $\approx 56\%$ (la promesa de sección 9). **Veredicto: el Mundial real salió mejor que la promesa — 0.861 y 62.5% (Figura 3).**

Los grupos y el detalle de los 72 partidos

Tarjetas por grupo con los clasificados modales y la tabla analítica con marcadores, goles esperados y probabilidades de goleada. **Veredicto: 27 de los 32 clasificados modales avanzaron. La máxima goleada prevista (Brasil–Haití, 33%) terminó 3–0; la segunda (Canadá–Catar,**

27%), 6–0. Los “más parejos” (Cabo Verde–Arabia 36/29/35 y Colombia–Portugal) terminaron 0–0.

El camino por rondas: los anfitriones

México con 25% de llegar a cuartos y 2.0% de título. **Veredicto: llegó a octavos y cayó 2–3 con Inglaterra en el Azteca — la descripción de su techo fue justa.**

El cuadro: la final anunciada

Desembocaba en España 1–1 Argentina, «campeón más probable: España (gana esta final con 56%)», anotando que una final así “bien podría definirse en penales”. **Veredicto: la final real fue 0–0 a los 90 minutos y 1–0 en la prórroga. El guion, no solo el titular.**

El hilo conductor — México vs. Sudáfrica. Cierre del hilo conductor. El 11 de junio, ante 87 mil personas en el Azteca, **México venció 2–0 a Sudáfrica** (Quiñones y Jiménez). El pronóstico 71/19/10 con marcador 1–0 vio caer el resultado en su región más probable — y el sistema, esa misma noche, ya estaba re-entrenándose con el partido en la panza. Así funcionó todo el torneo, para los 104 partidos.

12 El torneo en vivo: seis reentrenamientos y una lección

¿Cómo se mantiene vivo un pronóstico cuando la realidad avanza? Protocolo fijo, verificación paranoica — y la lección conceptual más valiosa del proyecto.

El protocolo de cinco pasos

Cada actualización siguió el mismo procedimiento: **(1) capturar** los resultados reales (los de grupos en un CSV editable hasta en Excel; los de eliminación con el ganador explícito, por los penales); **(2) verificar** contra fuente oficial; **(3) reconstruir** las señales — el Elo absorbe los partidos nuevos naturalmente: España pasó de 2291 a 2416 durante el torneo; **(4) reentrenar** dando triple peso a los partidos de *este* Mundial, vía pesos de muestra y no duplicando filas, que habría contaminado el tramo de calibración (mejora aportada por Codex); y **(5) fijar** lo jugado para re-simular *solo* el futuro.

La verificación que atrapó un error real

El CSV traía Argelia–Austria 1–2 cuando el partido real fue 3–3. El error no se encontró releendo el CSV, sino porque *sus consecuencias* no cuadraban: los clasificados simulados contradecían a los oficiales (Irán dentro, Argelia fuera). Moraleja de ingeniería: valida los datos contra una consecuencia observable, no solo contra la fuente.

La lección conceptual: duelo directo $\neq$ favorito

La lección llegó el 6 de julio como una contradicción visible: la portada decía “Francia favorita (20.2%)” y el cuadro terminaba en “España campeona”. Ambas cosas eran ciertas — y juntas,

incomprensibles. La causa: el cuadro se resolvía cruce por cruce por *duelo directo* (España le gana a Francia el cara a cara 52/48), mientras el favorito global mide *quién llega más lejos sumando todos los caminos*. El ejemplo que lo desnuda: Inglaterra “ganaba” su semifinal contra Argentina sin ser mejor —Argentina tenía mejor Elo y el duelo directo era 50/50— simplemente porque Inglaterra ya tenía un boleto que Argentina aún debía ganar en la cancha: 36% contra 25% de llegar a la final. La solución fue cambiar la regla del cuadro: **en cada cruce avanza quien tiene más probabilidad de alcanzar la siguiente instancia**. Con esa regla el cuadro desemboca en el favorito global *por construcción* — y la regla se explicó dentro del propio reporte, porque documentar el criterio vale tanto como implementarlo.

La Figura 2 y la Tabla 5 cuentan el resto: cómo el favorito fue cambiando de manos hasta la coronación.




Figura 2: La evolución del favorito: probabilidad de título de las cinco candidatas en las siete fechas del proyecto. Francia lideró mientras España debía cruces; desde el 9 de julio España recuperó la punta y no la soltó hasta la copa.

Fecha	Partidos	Estado	Favorito	Qué lo movió
10 jun	0	pre-torneo	España 14.6%	La apuesta base: final España–Argentina
1 jul	81	grupos + 9 R32	Francia 17.4%	9/9 en grupos; España aún debía su cruce
6 jul	92	+ 4 octavos	Francia 20.2%	Noruega eliminó a Brasil
9 jul	96	octavos listos	España 22.0%	1–0 a Portugal; recuperó la punta y no la soltó
13 jul	100	cuartos listos	España 28.6%	4/4 aciertos del modelo en cuartos
16 jul	102	semis listas	España 56.2%	2–0 a Francia; la final predicha, confirmada
19 jul	104	FINAL	España campeona	1–0 en prórroga (Ferran Torres, 106’)

Tabla 5: Cronología del favorito en las seis actualizaciones en vivo.

FORMULACIÓN MATEMÁTICA

La regla del favorito por instancia, con la que se resuelve el cuadro:

$$e^* = \arg \max_{e \in \{e_1, e_2\}} \pi_R(e), \quad (14)$$

donde:

- e_1, e_2 — las dos selecciones del cruce en la ronda R
- $\pi_R(e)$ — la probabilidad (por simulación) de que e alcance la ronda *siguiente* a R
- e^* — quien avanza en el cuadro mostrado — salvo que el cruce ya se haya jugado, en cuyo caso manda el resultado real

13 El veredicto: cuánto fue señal y cuánto moneda

La cuenta final, punto por punto — y la pregunta honesta: ¿el acierto fue mérito del modelo o suerte?

Primero, el desenlace oficial del torneo, para tener el marco completo: **campeona, España** (1–0 a Argentina en la prórroga de la final, gol de Ferran Torres al minuto 106); **subcampeona, Argentina**; **tercero, Inglaterra** (6–4 a Francia en el partido con más goles de un tercer puesto en la historia); **cuarto, Francia**. España cerró un torneo perfecto: ocho victorias, dieciséis goles a favor y tres en contra.

Ahora, la cuenta, punto por punto. Cada bloque enuncia lo que el documento del 10 de junio predijo, lo que ocurrió, y el veredicto.

1 • La campeona.

Se predijo: España, favorita con 14.6%

Ocurrió: España campeona del mundo

Veredicto: **ACIERTO EXACTO**

2 • La final.

Se predijo: España vs. Argentina

Ocurrió: España 1–0 Argentina

Veredicto: **ACIERTO EXACTO**

3 • El guion de la final.

Se predijo: «Final cerrada, 1–1 en 90 minutos, bien podría definirse en penales»

Ocurrió: 0–0 en 90 minutos; gol de la victoria al minuto 106, en la prórroga

Veredicto: **ACIERTO de guion**

4 • El ganador de esa final.

Se predijo: España la gana con 56%

Ocurrió: La ganó (la última actualización decía 56.2%)

Veredicto: **ACIERTO**

5 · Los cinco grandes.

Se predijo: Top-5: España, Francia, Argentina, Brasil, Inglaterra

Ocurrió: Los cuatro semifinalistas reales fueron los puestos 1, 2, 3 y 5; Brasil cayó en octavos con Noruega

Veredicto: **4 de 5**

6 · Los clasificados de grupos.

Se predijo: 32 clasificados del escenario modal

Ocurrió: 27 de ellos avanzaron en la realidad

Veredicto: **84%**

7 · Los 72 partidos, uno a uno.

Se predijo: Acierto 1X2 esperado $\approx 56\%$ (la promesa del examen)

Ocurrió: 45 de 72 correctos (62.5%), con log-loss 0.861

Veredicto: **MEJOR que lo prometido**

8 · Las goleadas.

Se predijo: Brasil–Haití la más probable (33%); Canadá–Catar segunda (27%)

Ocurrió: Terminaron 3–0 y 6–0

Veredicto: **ACIERTO**

9 · Los más parejos.

Se predijo: Cabo Verde–Arabia Saudita (36/29/35) y Colombia–Portugal

Ocurrió: Ambos terminaron 0–0

Veredicto: **ACIERTO**

10 · El anfitrión.

Se predijo: México: 25% de llegar a cuartos, 2.0% de título

Ocurrió: Llegó a octavos y cayó 2–3 con Inglaterra en el Azteca

Veredicto: Descripción justa de su techo

11 · La recta final.

Se predijo: Ganadores pronosticados de cuartos en adelante (en vivo)

Ocurrió: 7 de 7: los cuatro cuartos, las dos semifinales y la final

Veredicto: **PLENO**

12 · Los fallos.

Se predijo: Colombia favorita 51/49 sobre Suiza; Francia 52/48 en el tercer puesto

Ocurrió: Suiza avanzó por penales; Inglaterra ganó 6–4 el tercer puesto

Veredicto: Dos volados perdidos, reconocidos




Figura 3: La promesa contra la realidad: el modelo prometió en su examen una log-loss de ≈ 0.943 y en el Mundial real logró 0.861 — mejor de lo prometido, y muy lejos del azar.

Y la prueba visual de la segunda vara — la honestidad de los porcentajes — sobre los 72 partidos reales:




Figura 4: Calibración en el Mundial real: cada punto compara lo que el modelo prometió (eje horizontal) con la frecuencia con que ocurrió (eje vertical); el número junto a cada punto es cuántas predicciones caen en ese rango. Sobre la diagonal punteada, la promesa se cumple exactamente. El tramo 50–70% incluso sobre-cumplió: los favoritos ganaron más de lo prometido.

La interpretación honesta: una campeona con 14.6% *no* gana 6 de cada 7 réplicas del torneo — el pleno de portada incluyó una moneda cayendo del lado correcto. Lo que no fue moneda: los cuatro semifinalistas en el top-5 del ranking, la log-loss real superando la promesa del examen sobre 72 partidos, las goleadas y los empates cayendo donde el modelo los señaló, y la calibración estable a través de seis reentrenamientos. En las varas de sección 3: la evidencia de calidad es la log-loss y la calibración — y el titular, además, fue correcto.

PARTE V

El legado

Qué queda cuando termina el torneo: el plan concreto de mejora para 2030 con su porqué (sección 14) y la conclusión con las tres ideas que valen más que cualquier fórmula (sección 16). Los apéndices guardan los parámetros exactos, el registro de decisiones y el glosario.

14 Rumbo a 2030: mejoras y reproducción

El backlog priorizado —cada mejora con su porqué— y los seis pasos para recrear el sistema.

Backlog priorizado. (1) *xG y datos de eventos* (alta): actualizar ratings por rendimiento y no solo por resultado — un 0–1 dominando no debería castigar igual que un 0–1 dominado; reevaluar la cobertura pública en 2029 [6]. (2) *Modelo de penales* (alta): tres cruces se definieron en tandas tratadas como casi-volados; `shootouts.csv` espera. (3) *Automatización del modo en vivo* (alta): captura por API, verificaciones de consistencia como la que atrapó el 3–3 de Argelia, reentrenamiento programado — con humano aprobando, no tecleando. (4) *El problema del empate* (media): 20 de 72 partidos de grupos empataron y el 1X2 casi nunca los favorece; explorar un clasificador de empate como séptimo panelista. (5) *Desempates FIFA completos* (media): head-to-head y fair play en la simulación. (6) *Partidos sin tensión* (baja): el 3er puesto terminó 6–4; los amistosos de lujo piden lambdas infladas. (7) *Valor de plantilla dinámico* (baja).

Reproducción en seis pasos. (1) Reunir `results.csv` actualizado (fixture como filas vacías) y `squad_2030.csv`. (2) Actualizar grupos, confederaciones y cuadro oficial del sorteo real. (3) Re-correr el examen agregando WC 2026, Euro 2028 y Copa América 2028 como ediciones, aplicando la regla de oro a todo cambio. (4) Ejecutar el pipeline (*Run All*, ~2 minutos) y verificar los invariantes. (5) Publicar el reporte pre-torneo *con fecha* — es el contrato. (6) Durante el torneo, el protocolo de sección 12. Archivos: `mundial_toto.ipynb`, `results.csv`, `squad_2026.csv`, `resultados_en_vivo.csv`, `wc_final_pipeline.py`, `README.md`; Python 3.10+ con `pandas`, `numpy`, `scipy`, `scikit-learn`, `xgboost` y `matplotlib`.

15 Preguntas frecuentes

Las dudas que este documento suele provocar, respondidas de frente.

Si España era “la favorita”, ¿por qué solo tenía 14.6%?

Porque en un torneo de 48 selecciones con eliminación directa, nadie puede tener mucho más. Ser favorito no significa “probablemente gana”; significa “nadie tiene más probabilidad que tú”. El 14.6% de España era, de hecho, un número alto: le daba un 50% más de chances que al segundo favorito.

El modelo acertó a la campeona. ¿Eso demuestra que es bueno?

Solo en parte — y el documento lo dice con todas sus letras (sección 13). Un evento de 14.6% que ocurre incluye una moneda cayendo del lado correcto. La evidencia seria de calidad está en los 72 partidos medidos con log-loss (0.861, mejor que la promesa) y en la calibración (los “70%” del

modelo ocurren el 70% de las veces). El titular fue el premio; las métricas son la prueba.

¿Por qué el modelo casi nunca pronostica empates?

Pronostica *probabilidades* de empate constantemente (típicamente 18–30%), pero rara vez es el resultado *más* probable de un partido, porque para serlo tendría que superar a ambas victorias a la vez. Por eso 20 de los 72 partidos de grupos terminaron en empate y casi todos contaron como “fallo” del 1X2 — aunque las probabilidades estuvieran bien puestas. Es la limitación conocida más importante (sección 14).

¿Se puede usar este modelo para apostar?

No es su propósito y este proyecto no lo recomienda. Las casas de apuestas incorporan información que este modelo excluye a propósito (alineaciones, lesiones, dinero de millones de apostadores) y cobran un margen que consume ventajas pequeñas. El valor del proyecto es metodológico y educativo.

Si lo corro de nuevo, ¿me dará los mismos números?

Sí: el pipeline fija las semillas aleatorias de la simulación, así que la ejecución es reproducible. Con datos idénticos, los 30,000 torneos simulados son los mismos.

¿Qué se necesita para correrlo?

Una computadora normal. El notebook completo —de los datos crudos a la simulación— corre en unos dos minutos con Python y seis bibliotecas estándar (sección 14). No hay GPU, ni servidores, ni datos de pago.

¿Qué fue lo más difícil del proyecto?

No fue ninguna fórmula: fue la disciplina. Decirle que no a mejoras razonables que no pasaban el examen, documentar los fallos con el mismo cariño que los aciertos, y detectar errores de datos por sus consecuencias (el 3–3 de Argelia). Lo segundo más difícil: mantener la coherencia entre todas las vistas del pronóstico cuando el torneo estaba en marcha (la lección del cuadro de favoritos, sección 12).

¿Qué le cambiarías primero para 2030?

Datos de eventos (xG) para calificar *rendimiento* y no solo resultado, y un modelo real de penales: tres cruces de este Mundial se decidieron en tandas que el modelo trató como casi-volados. El backlog completo, priorizado y con razones, está en sección 14.

16 Conclusión

Las tres ideas que valen más que cualquier fórmula.

Este proyecto demuestra que un sistema de predicción serio no necesita datos secretos ni modelos exóticos: necesita **disciplina**. Con dos archivos públicos, seis modelos conocidos y una regla de oro —nada entra sin ganar el examen—, el sistema publicó con fecha a la campeona del mundo y su final exacta, superó su propia promesa de rendimiento, y mantuvo la honestidad de sus porcentajes durante seis reentrenamientos en vivo. Las tres ideas rectoras, en una línea cada una: **la información fluye solo del pasado al futuro** (regla sagrada, sección 6); **toda mejora se demuestra, no se argumenta** (regla de oro, sección 9); y **todo número publicado nace del modelo, nunca de un teclado** —ningún reporte del proyecto contiene cifras tecleadas a mano: todas se generan desde el estado del modelo. El sistema queda documentado, reproducible y con su backlog priorizado. La cita es en 2030 — con xG, con modelo de penales, y con esta memoria sobre la mesa.

A La comparación completa: el 10 de junio contra el torneo real, fase por fase

Este anexo pone lado a lado, etapa por etapa, lo que el reporte del 10 de junio predijo y lo que el torneo entregó. En cada tabla, **negrita** marca los aciertos.

Fase de grupos: los 32 clasificados

El reporte publicó, grupo por grupo, quiénes avanzarían (los dos primeros y, con “3”, el mejor tercero cuando aplicaba). Resultado: **27 de 32 aciertos**, con cuatro grupos perfectos de tres y tres grupos perfectos de dos.

Grupo	Predicho (10 de junio)	Clasificados reales	Aciertos
A	México, Corea del Sur, Chequia ³	México, Sudáfrica	1/2
B	Canadá, Suiza, Bosnia ³	Suiza, Canadá, Bosnia ³	3/3
C	Brasil, Marruecos, Escocia ³	Brasil, Marruecos	2/2
D	Estados Unidos, Turquía	Estados Unidos, Australia, Paraguay ³	1/3
E	Alemania, Ecuador, Costa de Marfil ³	Alemania, Costa de Marfil, Ecuador ³	3/3
F	Países Bajos, Japón, Suecia ³	Países Bajos, Japón, Suecia ³	3/3
G	Bélgica, Egipto	Bélgica, Egipto	2/2
H	España, Uruguay	España, Cabo Verde	1/2
I	Francia, Noruega, Senegal ³	Francia, Noruega, Senegal ³	3/3
J	Argentina, Argelia, Austria ³	Argentina, Austria, Argelia ³	3/3
K	Portugal, Colombia	Colombia, Portugal, RD Congo ³	2/3
L	Inglaterra, Croacia, Ghana ³	Inglaterra, Croacia, Ghana ³	3/3
			27/32

Tabla 6: Fase de grupos: clasificados predichos contra reales, grupo por grupo. El “3” marca al mejor tercero; los aciertos se cuentan sobre los clasificados reales de cada grupo.

La eliminación directa: el cuadro predicho contra el torneo real

El cuadro del 10 de junio nombraba, ronda por ronda, a quién veía avanzando. Su comparación contra los que realmente avanzaron:

Ronda	El 10 de junio decía	Avanzaron de verdad	Aciertos
Dieciseisavos (avanzan 16)	Suiza , Alemania, Francia , Países Bajos, Ecuador, Brasil , México , Inglaterra , Estados Unidos , Bélgica , Colombia , España , Canadá , Argentina , Portugal , Turquía	Suiza , Paraguay, Francia , Marruecos, Noruega, Brasil , México , Inglaterra , Estados Unidos , Bélgica , Colombia , España , Canadá , Argentina , Portugal , Egipto	12/16
Octavos (avanzan 8)	Países Bajos, Francia , Brasil, Inglaterra , España , Bélgica , Argentina , Portugal	Marruecos, Francia , Noruega, Inglaterra , España , Bélgica , Argentina , Suiza	5/8
Cuartos (avanzan 4)	Francia , España , Brasil, Argentina	Francia , España , Inglaterra, Argentina	3/4
Semifinales (avanzan 2)	España , Argentina	España , Argentina	2/2
LA FINAL	España campeona (le ganaba a Argentina con 56%)	España campeona , 1–0 a Argentina en la prórroga	EXACTO

Tabla 7: La eliminación directa, ronda por ronda: el cuadro modal del 10 de junio contra lo ocurrido. Cuanto más se acerca la final, más acierta el cuadro — hasta el pleno de la final exacta con su campeona.

La lectura de conjunto: el cuadro se equivocó donde las probabilidades eran cortas (dieciseisavos con favoritos del 52–55%) y acertó en pleno donde el torneo se decidía — **la semifinal exacta, la final exacta y la campeona exacta**, nombradas 39 días antes.

Los 72 partidos de la fase de grupos

Para cada partido: el pronóstico publicado el 10 de junio —probabilidades 1X2 (local/empate/visita) y marcador más probable— contra el resultado real. La palomita marca los partidos donde el resultado real fue el que el modelo tenía como más probable: 45 de 72 (62.5%).

G	Partido	1X2 (%)	Marcador pron.	Real	
A	México–Sudáfrica	71/19/10	1–0	2–0	✓
A	Corea del Sur–Chequia	43/30/28	1–1	2–1	✓
A	Chequia–Sudáfrica	53/26/20	1–0	1–1	×
A	México–Corea del Sur	54/26/20	1–1	1–0	✓
A	México–Chequia	58/24/18	1–1	3–0	✓
A	Sudáfrica–Corea del Sur	20/28/52	0–1	1–0	×
B	Canadá–Bosnia	62/22/16	2–0	1–1	×
B	Catar–Suiza	10/22/69	1–1	1–1	×
B	Canadá–Catar	77/15/8	2–0	6–0	✓
B	Suiza–Bosnia	61/23/15	1–0	4–1	✓
B	Bosnia–Catar	56/24/20	1–1	3–1	✓
B	Canadá–Suiza	39/30/31	1–1	1–2	×
C	Brasil–Marruecos	51/28/21	1–0	1–1	×
C	Haití–Escocia	25/29/46	1–1	0–1	✓
C	Brasil–Haití	78/15/6	2–0	3–0	✓
C	Escocia–Marruecos	24/30/46	0–1	0–1	✓
C	Marruecos–Haití	68/21/11	1–1	4–2	✓
C	Escocia–Brasil	15/26/59	0–2	0–3	✓
D	Estados Unidos–Paraguay	50/27/23	2–0	4–1	✓
D	Australia–Turquía	29/30/41	1–1	2–0	×
D	Turquía–Paraguay	44/28/28	1–1	0–1	×
D	Estados Unidos–Australia	55/26/20	1–1	2–0	✓
D	Paraguay–Australia	43/28/28	1–1	0–0	×
D	Estados Unidos–Turquía	43/28/28	2–0	2–3	×
E	Alemania–Curazao	82/13/6	2–0	7–1	✓
E	Costa de Marfil–Ecuador	30/26/44	1–1	1–0	×
E	Ecuador–Curazao	76/16/8	1–1	0–0	×
E	Alemania–Costa de Marfil	55/25/20	1–1	2–1	✓
E	Curazao–Costa de Marfil	13/26/61	1–1	0–2	✓
E	Ecuador–Alemania	32/31/37	1–1	2–1	×
F	Países Bajos–Japón	46/27/26	1–1	2–2	×
F	Suecia–Túnez	52/27/21	0–0	5–1	✓
F	Países Bajos–Suecia	55/26/20	1–1	5–1	✓
F	Túnez–Japón	18/26/55	1–1	0–4	✓
F	Japón–Suecia	47/28/25	1–1	1–1	×
F	Túnez–Países Bajos	13/25/62	1–1	1–3	✓

Tabla 8: Grupos A–F: pronóstico del 10 de junio contra resultado real.

G	Partido	1X2 (%)	Marcador pron.	Real	
G	Bélgica-Egipto	57/24/18	1-0	1-1	×
G	Irán-Nueva Zelanda	49/28/24	1-0	2-2	×
G	Bélgica-Irán	61/22/17	1-1	0-0	×
G	Nueva Zelanda-Egipto	24/32/44	0-0	1-3	✓
G	Egipto-Irán	43/28/30	0-1	1-1	×
G	Nueva Zelanda-Bélgica	12/26/62	1-1	1-5	✓
H	Arabia Saudita-Uruguay	13/25/62	0-1	1-1	×
H	España-Cabo Verde	83/12/5	2-0	0-0	×
H	España-Arabia Saudita	82/13/5	1-0	4-0	✓
H	Uruguay-Cabo Verde	69/21/11	1-0	2-2	×
H	Cabo Verde-Arabia Saudita	36/29/35	0-1	0-0	×
H	Uruguay-España	19/27/54	1-1	0-1	✓
I	Francia-Senegal	58/25/17	1-0	3-1	✓
I	Irak-Noruega	13/26/62	0-0	1-4	✓
I	Francia-Irak	80/14/6	1-0	3-0	✓
I	Noruega-Senegal	43/30/27	0-1	3-2	✓
I	Noruega-Francia	25/29/46	0-1	1-4	✓
I	Senegal-Irak	65/22/13	0-0	5-0	✓
J	Argentina-Argelia	61/23/15	1-1	3-0	✓
J	Austria-Jordania	63/22/15	1-1	3-1	✓
J	Argentina-Austria	62/24/14	1-0	2-0	✓
J	Jordania-Argelia	16/29/55	0-1	1-2	✓
J	Argelia-Austria	40/30/30	1-1	3-3	×
J	Jordania-Argentina	6/19/75	0-1	0-2	✓
K	Portugal-RD Congo	69/20/11	2-0	1-1	×
K	Uzbekistán-Colombia	16/28/55	0-1	1-3	✓
K	Colombia-RD Congo	60/24/15	1-0	1-0	✓
K	Portugal-Uzbekistán	70/19/10	1-0	5-0	✓
K	Colombia-Portugal	31/32/37	0-1	0-0	×
K	RD Congo-Uzbekistán	40/27/33	1-1	3-1	✓
L	Inglaterra-Croacia	56/26/17	1-0	4-2	✓
L	Ghana-Panamá	44/25/31	1-1	1-0	✓
L	Inglaterra-Ghana	71/19/10	1-0	0-0	×
L	Panamá-Croacia	18/28/53	1-1	0-1	✓
L	Croacia-Ghana	56/25/19	1-1	2-1	✓
L	Panamá-Inglaterra	9/23/69	0-1	0-2	✓

Tabla 9: Grupos G-L: pronóstico del 10 de junio contra resultado real.

Los 32 partidos de la eliminación directa

Las eliminatorias enfrentaron cruces que el 10 de junio no podía conocer (dependían de los grupos). Para compararlas con una sola vara, se usa *el mismo modelo publicado*: para cada cruce real, quién era su favorito y con qué probabilidad de avanzar (en cancha neutral), y su marcador más probable de 90 minutos. El favorito del modelo avanzó en 27 de 32 cruces.

Ronda	Cruce	Favorito del modelo	Marcador pron.	Real (avanzó)	
Dieciseisavos	Sudáfrica–Canadá	Canadá (70%)	0–1	0–1 (Canadá)	✓
Dieciseisavos	Brasil–Japón	Brasil (68%)	1–0	2–1 (Brasil)	✓
Dieciseisavos	Alemania–Paraguay	Alemania (68%)	2–0	1–1, pen. (Paraguay)	×
Dieciseisavos	Países Bajos–Marruecos	Países Bajos (57%)	1–1	1–1, pen. (Marruecos)	×
Dieciseisavos	Noruega–Costa de Marfil	Noruega (61%)	1–1	2–1 (Noruega)	✓
Dieciseisavos	Francia–Suecia	Francia (74%)	1–0	3–0 (Francia)	✓
Dieciseisavos	México–Ecuador	Ecuador (51%)	1–1	2–0 (México)	×
Dieciseisavos	Inglaterra–RD Congo	Inglaterra (82%)	2–0	2–1 (Inglaterra)	✓
Dieciseisavos	Bélgica–Senegal	Bélgica (61%)	1–1	3–2 (Bélgica)	✓
Dieciseisavos	Estados Unidos–Bosnia	Estados Unidos (71%)	1–0	2–0 (Estados Unidos)	✓
Dieciseisavos	España–Austria	España (79%)	2–0	3–0 (España)	✓
Dieciseisavos	Portugal–Croacia	Portugal (66%)	1–1	2–1 (Portugal)	✓
Dieciseisavos	Suiza–Argelia	Suiza (60%)	1–1	2–0 (Suiza)	✓
Dieciseisavos	Argentina–Cabo Verde	Argentina (87%)	1–0	3–2 (Argentina)	✓
Dieciseisavos	Egipto–Australia	Egipto (53%)	1–1	1–1, pen. (Egipto)	✓
Dieciseisavos	Colombia–Ghana	Colombia (72%)	1–0	1–0 (Colombia)	✓
Octavos	Francia–Paraguay	Francia (75%)	1–0	1–0 (Francia)	✓
Octavos	Marruecos–Canadá	Marruecos (61%)	1–1	3–0 (Marruecos)	✓
Octavos	Noruega–Brasil	Brasil (60%)	0–2	2–1 (Noruega)	×
Octavos	México–Inglaterra	Inglaterra (62%)	0–1	2–3 (Inglaterra)	✓
Octavos	España–Portugal	España (64%)	1–1	1–0 (España)	✓
Octavos	Bélgica–Estados Unidos	Bélgica (63%)	1–1	4–1 (Bélgica)	✓
Octavos	Argentina–Egipto	Argentina (77%)	1–0	3–2 (Argentina)	✓
Octavos	Suiza–Colombia	Suiza (50%)	1–1	0–0, pen. (Suiza)	✓
Cuartos	Francia–Marruecos	Francia (65%)	1–1	2–0 (Francia)	✓
Cuartos	España–Bélgica	España (69%)	1–1	2–1 (España)	✓
Cuartos	Noruega–Inglaterra	Inglaterra (60%)	0–1	1–2 (Inglaterra)	✓
Cuartos	Argentina–Suiza	Argentina (68%)	1–0	3–1 (Argentina)	✓
Semifinales	Francia–España	España (54%)	1–1	0–2 (España)	✓
Semifinales	Argentina–Inglaterra	Argentina (54%)	1–1	2–1 (Argentina)	✓
3er puesto	Francia–Inglaterra	Francia (53%)	1–1	4–6 (Inglaterra)	×
LA FINAL	España–Argentina	España (59%)	1–1	1–0 (España)	✓

Tabla 10: Las 32 eliminatorias: favorito y marcador según el modelo del 10 de junio contra el resultado real. “pen.” = definido por penales; entre paréntesis, quién avanzó.

B Hoja de parámetros (v2, para copiar en 2030)

Componente	Parámetro	Valor
Elo	K ; pesos por torneo; localía; margen	24; 2.0/1.6/1.4/1.2/0.75; 100; $1 + \ln(1 + \Delta g)$
Entrenamiento	ventana; recencia ML; recencia DC	14 años; semivida 8 años; semivida 3 años (ventana 12)
Calibración	split; método	30% cronológico final; Nelder–Mead
Valor	w_V ; muestra de calibración	0.45; 556 partidos 2022+
Simulación	réplicas; goles máx.; penales	30,000; 8; $p^W + \frac{1}{2}p^D$
Modo en vivo	peso Mundial; flag confianza	$\times 3$ (<code>sample_weight</code>); <18 partidos/24 meses

Tabla 11: Parámetros finales del sistema.

C Registro consolidado de decisiones

Decisión	Alternativas	Elección y evidencia
Fuentes de datos	+ cuotas, + ranking FIFA, + xG	Solo historial + valor: reproducibilidad y mérito propio (sección 4).
Localía Elo	55, 80, 100, 120	100: estándar [2] y mejor examen (sección 5).
Recencia en ML	sin peso; semivida 4 u 8	8 años; la de 4 empeoró (sección 9).
Decay del DC	sin decay; semivida 3	Con decay y ρ por malla: mejora consistente (sección 7).
Ensemble vs mejor modelo	solo el logit	Ensemble por robustez; empate documentado (sección 8).
Peso del valor w_V	malla 0–0.60	0.45: codo de la curva out-of-sample (sección 7).
Split de calibración	aleatorio vs cronológico	Cronológico: el aleatorio filtra futuro (sección 8).
Peso en vivo	duplicar filas vs pesos	<code>sample_weight</code> $\times 3$: no contamina calibración (sección 12).
Resolución del cuadro	duelo directo vs favorito	Favorito por instancia: coherencia (sección 12).
Terceros del cuadro	húngaro vs tabla oficial	En vivo, la oficial; el húngaro admite varios óptimos (sección 10).
Penales	50/50; ajustado; submodelo	Ajustado $p^W + \frac{1}{2}p^D$; submodelo a 2030 (sección 14).
Números del reporte	manuales vs generados	Generados siempre desde el modelo: fuente única de la verdad.

Tabla 12: Las doce decisiones que definieron el sistema.

D Mapa de archivos del proyecto

Archivo	Qué es
<code>mundial_toto.ipynb</code>	El motor completo: 26 celdas que van de los datos crudos a la simulación y el modo en vivo. Ejecutar con <i>Run All</i> .
<code>results.csv</code>	El historial de 49,272 partidos (1872–2026) más el fixture del Mundial como filas sin marcador.
<code>squad_2026.csv</code>	Valores de plantilla Transfermarkt de las 48 selecciones.
<code>resultados_en_vivo.csv</code>	La plantilla del modo en vivo: los resultados de grupos se capturan aquí (editable en Excel).
<code>wc_final_pipeline.py</code>	Versión módulo del pipeline, importable desde otros scripts.
<code>README.md</code>	La guía operativa del repositorio, con el detalle de ejecución.
<code>10dejunio.pdf</code>	El reporte pre-torneo publicado: el “contrato” contra el que se calificó el modelo.
<code>Prediccion_Mundial_2026.pdf</code>	El reporte final del torneo (España campeona), generado por el mismo sistema.
<code>wc2026_outputs/</code>	Los entregables de datos (predicciones por partido, probabilidades por ronda) y reportes de cada actualización.

Tabla 13: Los archivos del proyecto y el papel de cada uno.

E Glosario

Cada término con la sección o ecuación donde se desarrolla.

1X2 Los tres resultados posibles del tiempo regular: gana el local (1), empate (X), gana el visitante (2).

Backtest rolling-origin El “examen”: evaluar el modelo entrenándolo solo con el pasado de cada torneo de prueba (sección 9).

Bootstrap Técnica de remuestreo para estimar la incertidumbre de una comparación (usada para validar las mejoras v2).

Brier / RPS Variantes cuadráticas de la log-loss; el RPS respeta el orden victoria–empate–derrota.

Calibración / ECE La honestidad de los porcentajes: que el “70%” ocurra el 70% de las veces (3).

Dixon–Coles El modelo de goles del panel: Poisson por equipo con corrección de marcadores bajos (8).

Elo Rating de fuerza que sube al ganar y baja al perder, ponderado por rival, torneo y margen (4).

Ensemble La combinación ponderada de los seis modelos en un solo pronóstico (sección 8).

Entrenar Ajustar los parámetros internos de un modelo usando ejemplos del pasado con respuesta conocida.

Leakage Fuga de información futura hacia el entrenamiento; el error que la regla sagrada hace imposible (sección 6).

Log-loss La métrica principal: premia dar probabilidad alta a lo que ocurrió (2).

Monte Carlo Método de simulación por sorteo repetido; aquí, jugar el torneo 30,000 veces (sección 10).

Nelder–Mead Algoritmo de optimización usado para aprender los pesos y la temperatura de la mezcla.

Notebook Documento de código ejecutable donde vive todo el sistema (`mundial_toto.ipynb`).

Point-in-time Calculado exclusivamente con información anterior al momento que se describe (sección 6).

Softmax Función que convierte números cualesquiera en probabilidades que suman 1.

Temperature scaling Recalibración de probabilidades mediante un único escalar T (sección 8).

xG Goles esperados: cuántos goles “merece” un equipo según sus tasas de anotación.

Referencias

- [1] Dixon, M. J. y Coles, S. G. (1997). *Modelling Association Football Scores and Inefficiencies in the Football Betting Market*. Journal of the Royal Statistical Society, Serie C, 46(2), 265–280.
- [2] World Football Elo Ratings. *About the ratings*. <https://www.eloratings.net/about>
- [3] Bunker, R. y Susnjak, T. (2024). *Machine Learning for Soccer Match Result Prediction*. arXiv:2403.07669.
- [4] Boice, J. (2022). *How Our World Cup Predictions Work*. FiveThirtyEight. <https://fivethirtyeight.com/features/how-our-2022-world-cup-predictions-work/>
- [5] Sheehan, D. *Predicting Football Results with Statistical Modelling: Dixon–Coles and Time-Weighting*. <https://dashee87.github.io>
- [6] StatsBomb / Hudl. *Open Data*. <https://github.com/statsbomb/open-data>
- [7] FIFA (2025). *Reglamento de la Copa Mundial de la FIFA 2026*, Annex C.
- [8] Transfermarkt. *Valores de mercado de selecciones nacionales* (junio de 2026). <https://www.transfermarkt.com>
- [9] Resultados verificados partido a partido: FIFA.com, ESPN, NBC/CBS Sports, Olympics.com (junio–julio de 2026).